MBA FIAP Inteligência Artificial & Machine Learning

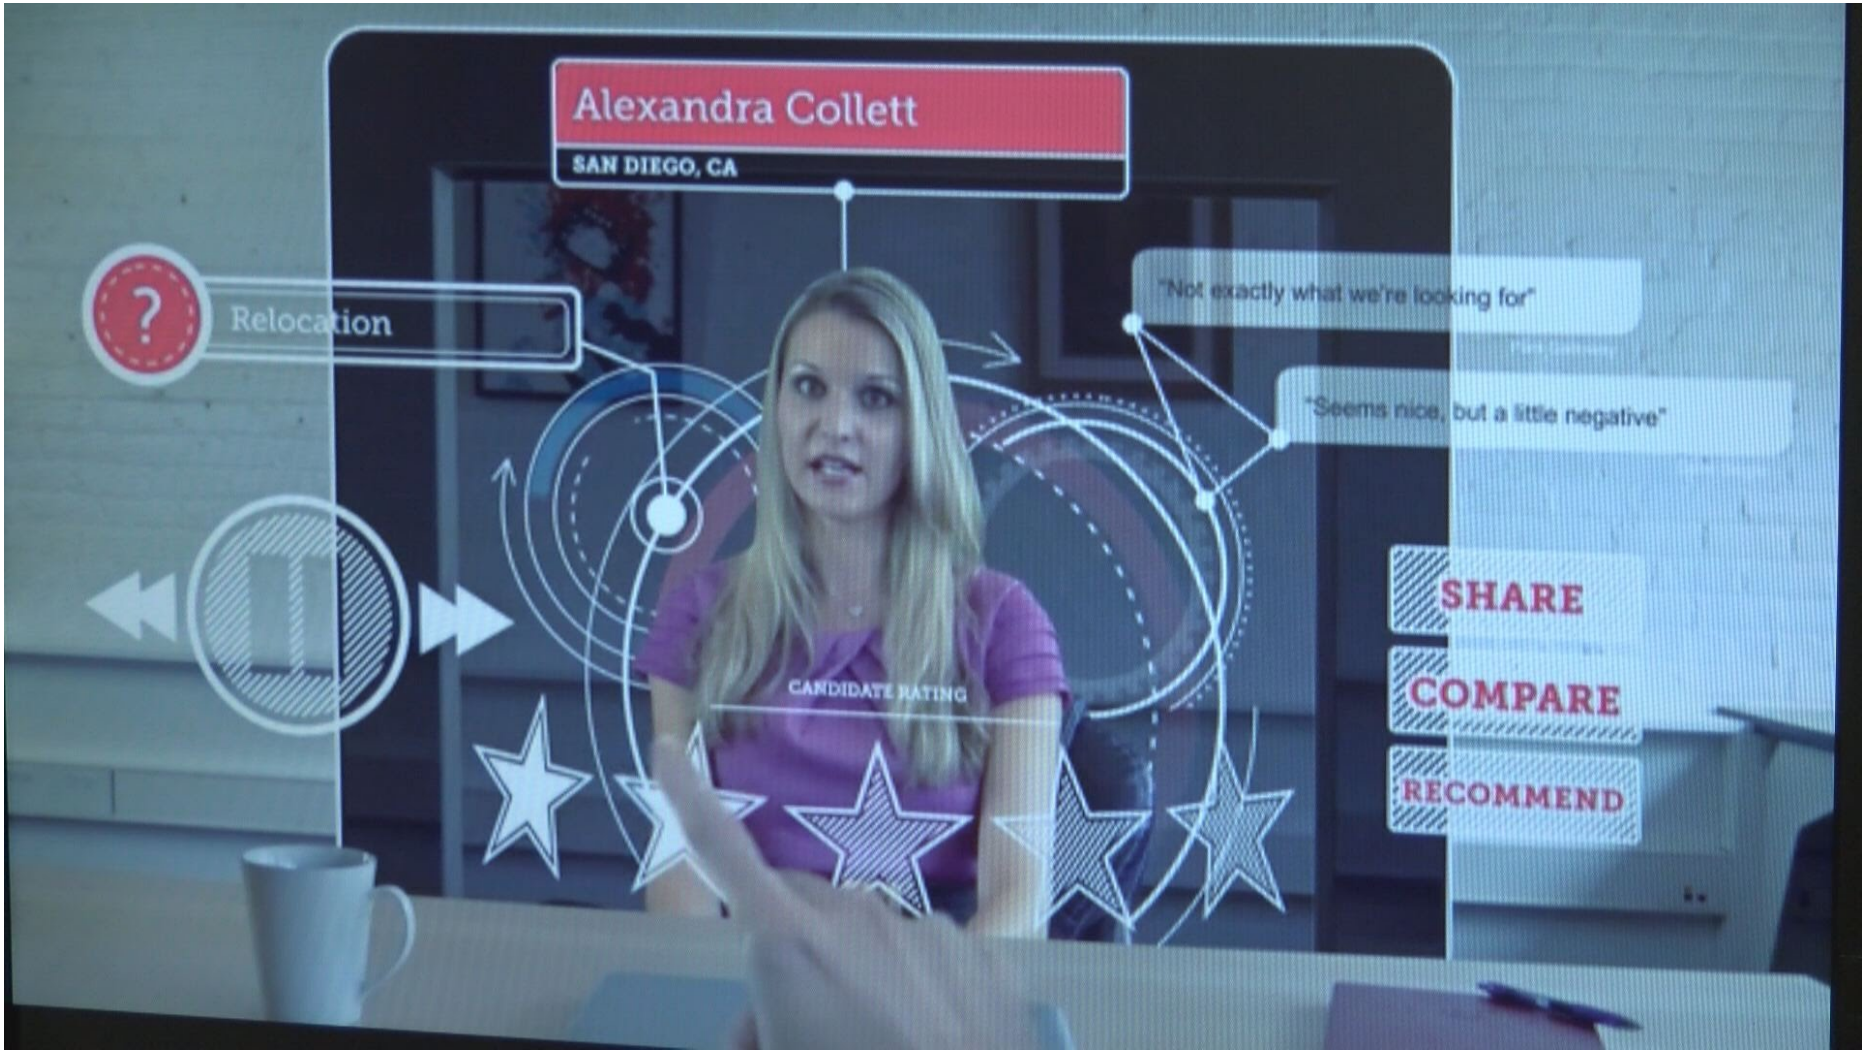

Tecnologia de Processamento de Imagens

Projeto Final Smart-Hiring: Entrevista Virtual

Este projeto final tem como objetivo explorar os conhecimentos adquiridos nas aulas práticas. Por meio uma trilha guiada para construir uma aplicação que tem por objetivo analisar imagens e extrair uma série de informações que serão utilizadas para compor uma análise de seleção de candidatos para uma entrevista simulada.

Este projeto poderá ser feita por grupos de até 4 pessoas.

Nome dos Integrantes	RM	Turma
Igor Leal Ribeiro Chaves	RM 331010	1IA

Por ser um projeto guiado, fique atento quando houver as marcações **Implementação** indica que é necessário realizar alguma implementação em Python no bloco a seguir onde há a inscrição `## IMPLEMENTAR` e **Resposta** indica que é esperado uma resposta objetiva relacionado a algum questionamento.

Cada grupo pode utilizar nas respostas objetivas quaisquer itens necessários que enriqueçam seu ponto vista, como gráficos, fotos e, até mesmo, trechos de código-fonte.

Pode-se utilizar quantos blocos forem necessários para realizar determinadas implementações ou utilizá-las para justificar as respostas. Não é obrigatório utilizar somente o bloco indicado.

Ao final não se esqueça de subir os arquivos do projeto nas contas do GitHub de cada membro, ou subir na do representante do grupo e os membros realizarem o fork do projeto.

A avaliação terá mais ênfase nos seguintes tópicos de desenvolvimento do projeto:

1. **Detector de objeto (cartão de identificação)**
2. **Detector de faces**
3. **Detector de sorriso**
4. **Detector de bocejo**
5. **Detector de olhos fechados**
6. **Descritor de objetos na cena**
7. **Conclusões Finais**

Introdução

Disclaimer: as informações do caso de uso de negócio são meramente ilustrativas para aplicar as tecnologias de visão computacional de forma mais aderente ao desafio proposto. Todos os comentários foram forjados para dar vazão aos desafios e não representam formas de avaliação de candidatos. A empresa em questão, a Wandee, é fictícia.

A empresa **Wandee**, especializada em entrevistas virtuais, está construindo um produto minimamente viável (MVP) para testar algumas tecnologias voltadas a

visão computacional para tornar o processo de seleção, especialmente a etapa de entrevista mais completo, rápido e que permita aos recrutadores obterem feedbacks mais completos além da profunidade técnica de cada posição, como por exemplo, se o candidato é ele mesmo (prova de identidade), se possuí o cartão de acesso a entrevista, aspectos de atenção durante a entrevista, como concentração e foco. Ainda será analisado questões de organização no local do entrevistado, buscando por objetos na visão da câmera.

Todo o processo de entrevista virtual é feito remotamente por meio de uma câmera (*webcam*). Logo, todos os algoritmos desenvolvidos precisam capturar as imagens desta origem.

1. Detector de objeto

Antes de começar com o processo de autenticação, os candidatos precisam utilizar o celular e exibir o ícone da empresa para a câmera. Se o resultado for positivo indica que o sistema pode avançar para a próxima etapa.

Construa um algortimo que seja capaz de analisar uma região de interesse específica (ROI, *Region of Interest*), capturada por vídeo, e valide se o ícone está presente ao ser exibido pelo celular do candidato.

Lembre-se que questões de proporção e rotação precisam ser consideradas na identificação.

Este processo precisa ser de rápida identificação, neste caso não será possível aplicar técnicas que envolvam aprendizado de máquina. É indicado o uso de detectores de objetos e extratores de características.

No seu smartphone abra o navegador e entre com o link [https://raw.githubusercontent.com/michelpf/fiap-ml-tec-proc-imagens-capstone/master/projeto-final/imagens/logo.png (https://raw.githubusercontent.com/michelpf/fiap-ml-tec-proc-imagens-capstone/master/projeto-final/imagens/logo.png)](https://raw.githubusercontent.com/michelpf/fiap-ml-tec-proc-imagens-capstone/master/projeto-final/imagens/logo.png)

Ou, escaneie com seu smartphone o QRCode abaixo.

In [1]:
```
import seaborn as sns
import matplotlib.pyplot as plt
import matplotlib.image as mpimg
import numpy # as np
import cv2
from os import listdir
from os.path import isfile, join
from scipy.spatial import distance as dist
import collections
from matplotlib.pyplot import figure

from IPython import display
import sys
import time
import dlib
from utils import *
from darknet import Darknet



%matplotlib inline
```

A função abaixo deve receber uma imagem capturada da região de interesse e comparar com a imagem template do logotipo de empresa. O retorno é o número de correspondências encontradas.

In [2]:
```
def detector(imagem, template):
    # Conversão da imagem e template par escala de cinza
    imagem_norm = cv2.cvtColor(imagem, cv2.COLOR_BGR2GRAY)
    template_norm = cv2.cvtColor(template, cv2.COLOR_BGR2GRAY)

    # IMPLEMENTAR
    #
    # Escolha um detector de imagens adequado, configure e aplique um algoritmo de match
    # Esta função deve retornar o número de correspondências de uma imagem versus seu template


    orb_detector = cv2.ORB_create()

    kps = orb_detector.detect(imagem_norm, None)
    kps_imagem, desc_imagem = orb_detector.compute(imagem_norm, kps)

    kps = orb_detector.detect(template_norm, None)
    kps_template, desc_template = orb_detector.compute(template_norm, kps)

    FLANN_INDEX_LSH = 6
    index_params= dict(algorithm = FLANN_INDEX_LSH, table_number = 6, key_size = 12, multi_probe_level = 1)

    search_params = dict(checks=50)

    flann = cv2.FlannBasedMatcher(index_params, search_params)

    matches = flann.knnMatch(desc_imagem, desc_template, k=2)



    #good_matches = []
    #
    #try:
    #    for (m,n) in matches:
    #        if m.distance < 0.8*n.distance:
    #            good_matches.append(m)
    #except:
    #    pass

    #return len(good_matches)


    return len(matches)
```

Carregue a imagem de template.

In [3]:
```
image_template = cv2.imread("imagens/logo.png")
cv2.imshow("Logo_Wandee", image_template)
#cv2.waitKey()
cv2.destroyAllWindows()
```

Utilize a função `detector` para obter as correspondências identificadas. Por meio de testes prévios, estabeleça qual o valor de *matches* para o template definido. Isto pode fazer com que ajuste valores do detector ORB para ajustes, é um processo de experimentação.

Após definir o limiar, desenvolva uma regra para comparar com o valor de *matches* e exibir em tempo real se o template foi localizado.

In [4]:
```
# Função de suporte para exibição de imagens no Jupyter

def exibir_imagem(imagem):
    #figure(num=None, figsize=(15, 10))
    image_plt = mpimg.imread(imagem)
    plt.imshow(image_plt)
    plt.axis('off')
    plt.show()
```

O trecho de códido abaixo é para iniciar a captura de imagens da câmera. Nela será definido uma região de interesse que deverá ser capturado uma imagem para acionar a função de detecção.

In [5]:
```
#### test  para capturarwebcam

#captura da webcam
#video_capture = cv2.VideoCapture(0)

#while True:
#    # Captura a cada frame
#    ret, frame = video_capture.read()
#    cv2.imshow('Webcam',frame)
#    if cv2.waitKey(1) & 0xFF == ord('q'):
#        break
#
##Fechar a janela
#video_capture.release()
#cv2.destroyAllWindows()
```

In [7]:
```
cv2.destroyAllWindows()
cap = cv2.VideoCapture(0)


while True:
    # Obtendo imagem da câmera
    ret, frame = cap.read()

    if ret:
        # Definindo região de interesse (ROI)
        height, width = frame.shape[:2]
        top_left_x = int(width / 3)
        top_left_y = int((height / 2) + (height / 4))
        bottom_right_x = int((width / 3) * 2)
        bottom_right_y = int((height / 2) - (height / 4))

        # Desenhar retângulo na região de interesse
        cv2.rectangle(frame, (top_left_x,top_left_y), (bottom_right_x,bottom_right_y), 255, 3)

        # Obtendo região de interesse para validação do detector
        cropped = frame[bottom_right_y:top_left_y , top_left_x:bottom_right_x]

        # Executando o detector, definindo um limiar e fazendo a comparação para validar se o logotipo foi detectado
        # IMPLEMENTAR

        number_matches = detector(cropped, image_template)

        threshold = 400

        if number_matches >= threshold:
            cv2.putText(frame, "Logo Detectado", (10,30), cv2.FONT_HERSHEY_SIMPLEX, 1, (0,255,0), 2)
            cv2.imwrite("imagens/Evidencia1_logo-detectado.png", frame)
            break
        cv2.imshow("Identificacao de Template", frame)

    # Se for teclado Enter (tecla 13) deverá sair do loop e encerrar a captura de imagem
    if cv2.waitKey(1) == 13:
        break

cap.release()
cv2.destroyAllWindows()
```

Armazene uma evidência do logotipo detectado, exibindo na imagem a região de interesse com a imagem.

In [8]:
```
# IMPLEMENTAR
# Passe o parâmetro localização da imagem para exibi-la no notebook

exibir_imagem("imagens/Evidencia1_logo-detectado.png")
```

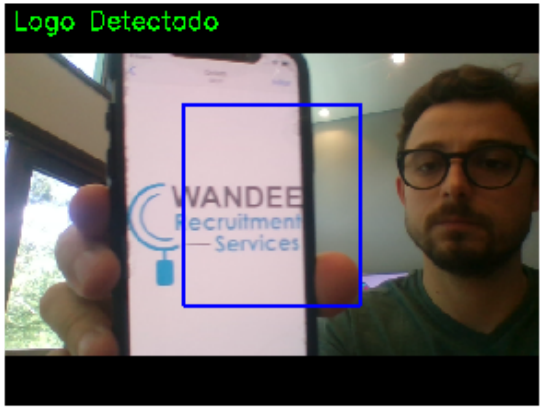

2. Detector de faces

Para validação de autenticidade do candidado, o processo de entrevista virtual precisa confirmar se a pessoa selecionada para a entrevista é a mesma. Neste caso a técnica a ser utilizada é por meio de um reconhecimento facial,

Inicialmente, precisamos treinar um classificador próprio do OpenCV com exemplos de imagem do candidato. Eleja uma pessoa do grupo para ser o candidato e treine um conjunto de imagens suficiente para que seja possível alcançar similaridade, onde o valor de não similaridade seja de até 40 pontos. O algortimo de similaridade de faces utiliza um sistema que quando a face é idêntica, o número de pontos é igual a 0, se for totalmente diferente, tende ao infinito. Logo, patamar de 30 a 40 é um bom número de similaridade.

Implementação

Nesta etapa inicial será realizado o treinamento das faces de um determinado candidato. Você precisará coletar um número de imagens relevante do candidato. Além disso, é recomendável aplicação de um detector de faces para que seja extraído somente a *região de interesse* ou seja, a própria face. Uma maneira de conseguir este tipo de segmentação é utilizando um classificador em cascada de Haar treinado para este fim.

Utilize a função a abaixo para segmentar o rosto de uma imagem.

In [9]:
```
face_classifier = cv2.CascadeClassifier('classificadores/haarcascade_frontalface_default.xml')

def face_extractor(img):
    gray = cv2.cvtColor(img,cv2.COLOR_BGR2GRAY)
    faces = face_classifier.detectMultiScale(gray, 1.2, 5)

    if faces is ():
        return None

    for (x,y,w,h) in faces:
        cropped_face = img[y:y+h, x:x+w]

    return cropped_face
```

In [10]:
```
face_classifier = cv2.CascadeClassifier('classificadores/haarcascade_frontalface_default.xml')

def face_detector(img):
    gray = cv2.cvtColor(img,cv2.COLOR_BGR2GRAY)
    faces = face_classifier.detectMultiScale(gray, 1.2, 5)
    if faces is ():
        return img, [], 0, 0
    for (x,y,w,h) in faces:
        cv2.rectangle(img,(x,y),(x+w,y+h),(0,255,255),2)
        roi = img[y:y+h, x:x+w]
        roi = cv2.resize(roi, (300, 300))
    return img, roi, x, y
```

Crie um algoritmo para que treine um determinado número de faces, escolhido pelo grupo, par que seja armazenado em um diretório específico para posteior treinamento.

In [11]:
```
cv2.destroyAllWindows()
#cap = cv2.VideoCapture(0)

contagem = 0

# IMPLEMENTAR
# Defina o número máximo de imagens a serem coletadas
contagem_maxima = 200

video_capture = cv2.VideoCapture(0)

while True:
    # Captura a cada frame
    ret, frame = video_capture.read()
    cv2.imshow('Webcam',frame)


    # IMPLEMENTAR
    # Crie um algoritmo para salvar as imagens segmentadas em face em um determinado diretório
    contagem += 1
    face = cv2.resize(face_extractor(frame), (300, 300))
    face = cv2.cvtColor(face, cv2.COLOR_BGR2GRAY)

    cv2.imwrite('imagens/TreinoRosto/' + str(contagem) + '.jpg', face)

    # Put count on images and display live count
    cv2.putText(face, str(contagem), (50, 50), cv2.FONT_HERSHEY_SIMPLEX, 1, (255,255,255), 2)
    cv2.imshow('TreinoRosto', face)

    # Se for teclado Enter (tecla 13) deverá sair do loop e encerrar a captura de imagem
    # ou for alcançado a contagem máxima (amostras)



    if cv2.waitKey(1) & 0xFF == ord('q') or contagem == contagem_maxima:
        break

#Fechar a janela
video_capture.release()
cv2.destroyAllWindows()
```

O treinamento utilizando é um próprio classificador de faces que o OpenCV possui. Neste caso vamos optar pelo classificador Local Binary Patterns Histograms (LBPH), que para este cenário é o mais adequado.

O grupo pode optar por escolher outros tipos de algoritmos do OpenCV, se desejarem.

In [12]:
```
# IMPLEMENTAR
# Defina o diretório utilizado para salvar as faces de exemplo

data_path = 'imagens/TreinoRosto/'

onlyfiles = [f for f in listdir(data_path) if isfile(join(data_path, f))]
training_data, labels = [], []

for i, files in enumerate(onlyfiles):
    image_path = data_path + onlyfiles[i]
    images = cv2.imread(image_path, cv2.IMREAD_GRAYSCALE)
    training_data.append(images)
    labels.append(0)
    #print(i)

# Criando uma matriz da lista de labels
labels = np.asarray(labels, dtype=np.int32)

# Treinamento do modelo
model = cv2.face.LBPHFaceRecognizer_create()
model.train(training_data, labels)

print("Modelo treinado com sucesso.")

# IMPLEMENTAR
# Defina na chave 0 o nome do candidato

persons = {0: 'IgorChaves'}
```

```
Modelo treinado com sucesso.
```

Vamos considerar uma classificação com sucesso quando a distândia de predição da face analisada for entre 30 e 40. Os valores de retorno destes classificador não é um índice de confiança.

Quando houver uma deteção dentro da margem de distância, armazene a imagem com o nome "success_candidate.png", constando as informações do nome do candidato e a distância identificada pelo classificador (retorno do método *predict*).

Escreva na tela onde a imagem da câmera é capturada a informação da distância de detecção da face extraída versus a face treinada, emuldure a face num retângulo e, se a face for devidadamente identificada, inclua um texto com a informação " `<Nome do candidato>` Reconhecido"

In [13]:
```
cap = cv2.VideoCapture(0)

while True:
    ret, frame = cap.read()
    image, face, x, y = face_detector(frame)

    try:
        face = cv2.cvtColor(face, cv2.COLOR_BGR2GRAY)
        results = model.predict(face)
        cv2.putText(image, "Resultado" + str(results[1]), (20, 20), cv2.FONT_HERSHEY_DUPLEX, 1, (0,0,255), 2)

        if x > 0:
            display_string = "Distancia: " + str(int(results[1]))
            cv2.putText(image, display_string, (x, y-20), cv2.FONT_HERSHEY_DUPLEX, 1, (255,120,150), 2)

        if int(results[1]) >= 30 and int(results[1]) <= 40:
            cv2.putText(image, 'IgorChaves Reconhecido com sucesso!!!', (x-250, y-50), cv2.FONT_HERSHEY_DUPLEX, 1, (0,255,0), 2)
            cv2.imshow('Face Recognition', image)
            cv2.imwrite("imagens/Evidencia2_RostoReconhecido.png", image)
            break
        else:
            cv2.putText(image, "Nao Reconhecido", (250, 450), cv2.FONT_HERSHEY_DUPLEX, 1, (0,0,255), 2)
            cv2.imshow('Face Recognition', image)
    except:
        cv2.putText(image, "Rosto Nao Identificado", (220, 120) , cv2.FONT_HERSHEY_DUPLEX, 1, (0,0,255), 2)
        cv2.putText(image, "Nao Reconhecido", (250, 450), cv2.FONT_HERSHEY_DUPLEX, 1, (0,0,255), 2)
        cv2.imshow('Face Recognition', image )


    # Se for teclado Enter (tecla 13) deverá sair do loop e encerrar a captura de imagem
    if cv2.waitKey(1) == 13: #13 is the Enter Key
        break

cap.release()
cv2.destroyAllWindows()
```

Guarde como evidência de classificação bem sucedida, uma imagem capturada da câmera durante o processo.

In [14]:
```
# IMPLEMENTAR
# Passe o parâmetro localização da imagem para exibi-la no notebook

exibir_imagem("imagens/Evidencia2_RostoReconhecido.png")
```

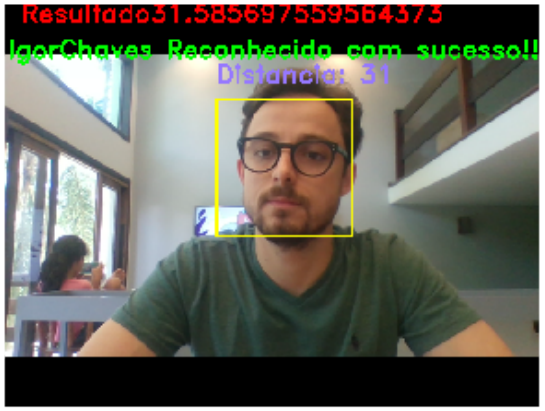

3. Detector de sorriso

Muitas empresas demandam que futuros empregados demonstrem educação, tranquilidade e empatia, características que podem ser evidencias com uma uma análise simples da receptividade do candidado por meio das expressões de seu rosto.

Um detector importante disto é sobre se o candidato mantém o semblante fechado ou se mantém um rosto alegre, oscilando sorrisos a medida que é realizada a entrevista e demais questionamentos.

Utilize as bibliotecas do *DLib*, em especial o preditor treinado para 68 pontos de marcação de face, para identificar a geometria dela e obtenha as marcações de interesse.

Uma das formas de extraírmos os pontos de contorno da face é utilizando o modelo do *DLib* `shape_predictor_68_face_landmarks.dat` . Este modelo retorna 68 pontos da face

In [15]:
```
predictor_68_path = "modelos/shape_predictor_68_face_landmarks.dat"

predictor = dlib.shape_predictor(predictor_68_path)
detector = dlib.get_frontal_face_detector()
```

Liste os pontos de cada parte do rosto. A partir deles poderão ser feitos estudos geométricos para identificar características relcioandos aos mesmos.

In [16]:
```
# IMPLEMENTAR
# Para cada constante abaixo, indique uma lista de pontos dos 68 identificados pelo classificador do DLib
FACE_POINTS = list(range(17, 68))
MOUTH_POINTS = list(range(48, 61))
RIGHT_BROW_POINTS = list(range(17, 22))
LEFT_BROW_POINTS = list(range(22, 27))
RIGHT_EYE_POINTS = list(range(36, 42))
LEFT_EYE_POINTS = list(range(42, 48))
NOSE_POINTS = list(range(27, 35))
JAW_POINTS = list(range(0, 17))
```

Crie uma função que será utilizada para identificar um sorriso. Leve em consideração estudos que envolvem cálculo de razão de aspecto geométrico e adapte para os pontos dos lábios.

Estude o paper de Soukupová e Čech de 2016 (http://vision.fe.uni-lj.si/cvww2016/proceedings/papers/05.pdf) para entender como obter um cálculo de aspecto de razão para formas geométricas da face. Você pode fazer aproximações a partir do estudo do paper para outras formas, como os lábios e olhos.

Crie uma função `month_aspect_ratio` que receba os pontos dos lábios e calcule o aspecto de razão para que seja exibida dados de quando a boca está aberta, fechada, dentre outros comportamentos.

In [17]:
```
def month_aspect_ratio(mouth):

    a = dist.euclidean(mouth[2], mouth[10])
    b = dist.euclidean(mouth[4], mouth[8])
    c = dist.euclidean(mouth[1], mouth[11])
    d = dist.euclidean(mouth[3], mouth[9])
    e = dist.euclidean(mouth[5], mouth[7])
    f = dist.euclidean(mouth[0], mouth[6])
    mar = (a + b + c + d + e) / (3.0 * f)

    return mar

def eye_aspect_ratio(eye):
    a = dist.euclidean(eye[1], eye[5])
    b = dist.euclidean(eye[2], eye[4])
    c = dist.euclidean(eye[0], eye[3])
    ear = (a + b) / (2.0 * c)

    return ear
```

Na função abaixo, inclua um segundo retorno que será a razão de aspecto dos lábios. Deixe como está o terceiro retorno, pois ele será estudado no próximo algoritmo.

In [18]:
```
def annotate_landmarks_convex_hull_image(im):
    im = im.copy()
    rects = detector(im, 1)

    if len(rects) == 0:
        return im, 0, 0

    landmarks_list = []

    for rect in rects:
        landmarks = numpy.matrix([[p.x, p.y] for p in predictor(im, rect).parts()])

        for k, d in enumerate(rects):
            cv2.rectangle(im, (d.left(), d.top()), (d.right(), d.bottom()), (0, 255, 0), 2)

            points = cv2.convexHull(landmarks[NOSE_POINTS])
            cv2.drawContours(im, [points], 0, (0, 255, 0), 1)

            points = cv2.convexHull(landmarks[MOUTH_POINTS])
            cv2.drawContours(im, [points], 0, (0, 255, 0), 1)

            points = cv2.convexHull(landmarks[RIGHT_BROW_POINTS])
            cv2.drawContours(im, [points], 0, (0, 255, 0), 1)

            points = cv2.convexHull(landmarks[LEFT_BROW_POINTS])
            cv2.drawContours(im, [points], 0, (0, 255, 0), 1)

            points = cv2.convexHull(landmarks[RIGHT_EYE_POINTS])
            cv2.drawContours(im, [points], 0, (0, 255, 0), 1)

            points = cv2.convexHull(landmarks[LEFT_EYE_POINTS])
            cv2.drawContours(im, [points], 0, (0, 255, 0), 1)

            month_aspect = month_aspect_ratio(landmarks[MOUTH_POINTS])

            eye_aspect = eye_aspect_ratio(landmarks[LEFT_EYE_POINTS])



    return im, month_aspect, eye_aspect
```

Realize ensaios para definir o valor de sorriso versos simulações com os lábios normais e aberto. Um sorriso é uma estado entre os lábios fechados ou semi-fechados e a boca inteiramente aberta. Definina abaixo os limiares inferior e superior para a identificação de um sorriso.

In [19]:
```
# IMPLEMENTAR
# Defina os valores mínimo e máximo para detecção do sorriso

sorriso_minimo = 0.50
sorrimo_maximo = 0.70
```

Após identificar o sorriso, contabilize quantas vezes foram identificados.

In [20]:
```
cv2.destroyAllWindows()
cam_capture = cv2.VideoCapture(0)

# Quantidade de sorrisos identificados
qtde_sorrisos = 0
sorriso = False

while True:
    ret, image_frame = cam_capture.read()
    prev_sorriso = sorriso
    if ret:
        image_frame, month_aspect, _ = annotate_landmarks_convex_hull_image(image_frame)
        cv2.putText(image_frame, "month_aspect " + str(month_aspect), (20, 20), cv2.FONT_HERSHEY_DUPLEX, 1, (0,0,255), 2)
        if (month_aspect > sorriso_minimo) and (month_aspect < sorrimo_maximo):
            sorriso = True
            cv2.putText(image_frame, 'Sorriso capturado', (20, 50), cv2.FONT_HERSHEY_DUPLEX, 1, (0,0,255), 2)
            cv2.imwrite('imagens/3.Sorriso/EvidenciaSorriso.png', image_frame)

        else:
            sorriso_encontrado = False

        if (prev_sorriso == True) and (sorriso == False):
            qtde_sorrisos += 1

        cv2.imshow("Detector de Sorriso", image_frame)

        # Se for teclado Enter (tecla 13) deverá sair do loop e encerrar a captura de imagem
        if cv2.waitKey(1) == 13:
            break
    else:
        break


cam_capture.release()
cv2.destroyAllWindows()
```

Armazene um exemplo de uma imagem, na pasta `imagens` com o sorriso detectado para exibição.

In [21]:
```
# IMPLEMENTAR
# Passe o parâmetro localização da imagem para exibi-la no notebook

exibir_imagem('imagens/3.Sorriso/EvidenciaSorriso.png')
```

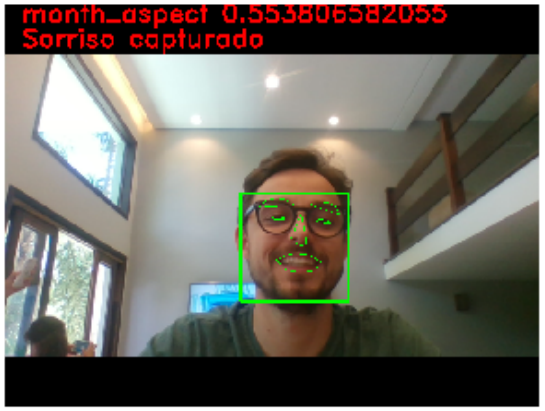

4. Detector de bocejos

Os candidados devem estar sempre atentos durante a entrevista virtual. Para garantir que ele se preparou adequadamente antes do início da entrevista não deverá ser tolerado bocejos.

Um detector de bocejos deverá utilizar aspectos das marcações dos lábios já definidas para identificar o bocejo. Neste caso o que será diferente é o valor da razão de aspecto.

Neste caso não há um limiar, como o bocejo é a boca aberta ao máximo, vamos definir um valor mínimo.

In [22]:
```
# IMPLEMENTAR
# Defina o valor mínimo de abertura dso lábios

bocejo_minimo = 0.80
```

In [23]:
```
cam_capture.release()

cam_capture = cv2.VideoCapture(0)
cv2.destroyAllWindows()

# Quantidade de bocejos identificados
qtde_bocejos = 0
bocejo = False

while True:
    ret, image_frame = cam_capture.read()
    prev_bocejo = bocejo

    if ret:
        image_frame, month_aspect, _ = annotate_landmarks_convex_hull_image(image_frame)
        cv2.putText(image_frame, "month_aspect " + str(month_aspect), (20, 20), cv2.FONT_HERSHEY_DUPLEX, 1, (0,0,255), 2)
        if (month_aspect > bocejo_minimo):
            cv2.putText(image_frame, "Bocejo identificado ", (20, 45), cv2.FONT_HERSHEY_DUPLEX, 1, (0,0,255), 2)
            cv2.imwrite('imagens/4.bocejo/EvidenciaBocejo.png', image_frame)
            bocejo = True

        else:
            bocejo_encontrado = False

        cv2.imshow("Detector de Bocejo", image_frame)

        # Se for teclado Enter (tecla 13) deverá sair do loop e encerrar a captura de imagem
        if cv2.waitKey(1) == 13:
            break

    else:
        break

cam_capture.release()
cv2.destroyAllWindows()
```

Armazene um exemplo de uma imagem, na pasta `imagens` com o bocejo detectado para exibição.

In [24]:
```
# IMPLEMENTAR
# Passe o parâmetro localização da imagem para exibi-la no notebook

exibir_imagem('imagens/4.bocejo/EvidenciaBocejo.png')
```

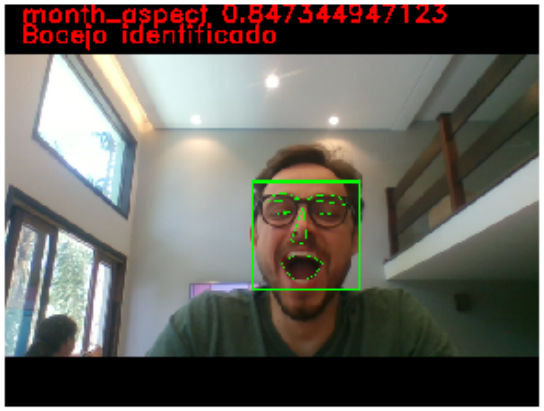

5. Detector de olhos fechados

A atenção durante um processo de entrevista é algo crucial, e mais marcante neste etapa do processo seletivo. Por esta razão é preciso identificar a quantidade de vezes que o entrevistado feche os olhos, para entendermos se ele de fato está atento as perguntas e ao processo como um todo.

Elabore um algoritmo que detecte os olhos fechados e contabilize ao final da transmissão.

Este caso requer um estudo também geométrico que visa analisar os pontos da marcação dos olhos. Para fins de simplificação, podemos adotar um único olho, e a partir dele, estebelecer o razão de aspecto para quando ele está aberto e fechado.

Construa uma função chamada `eye_aspect_ratio` para calcular o aspecto de razão de um dos olhos.

In [25]:
```
def eye_aspect_ratio(eye):
    a = dist.euclidean(eye[1], eye[5])
    b = dist.euclidean(eye[2], eye[4])
    c = dist.euclidean(eye[0], eye[3])
    ear = (a + b) / (2.0 * c)

    return ear
```

Altere a função `annotate_landmarks_convex_hull_image` para exibir, no terceiro parâmetro o valor de aspecto de um dos olhos.

No caso do olho, precisamos definir somente um valor máximo de limite.

In [26]:
```
# IMPLEMENTAR
# Defina um valor máximo para determinar se o olho está fechado
olho_maximo = 0.13
```

In [27]:
```
cam_capture.release()

cam_capture = cv2.VideoCapture(0)
cv2.destroyAllWindows()

#Quantidade de olhos fechados identificados
olhos_fechados = False
qtde_olhos_fechados = 0

while True:
    ret, image_frame = cam_capture.read()
    prev_olhos_fechados = olhos_fechados

    if ret:
        image_frame, _, eye_aspect = annotate_landmarks_convex_hull_image(image_frame)
        cv2.putText(image_frame, "eye_aspect " + str(eye_aspect), (20, 20), cv2.FONT_HERSHEY_DUPLEX, 1, (0,0,255), 2)
        if (eye_aspect < olho_maximo):
            cv2.putText(image_frame, "Olho Fechado ", (20, 45), cv2.FONT_HERSHEY_DUPLEX, 1, (0,0,255), 2)
            cv2.imwrite('imagens/5.olhos/EvidenciaOlhos.png', image_frame)
            olhos_fechados = True

        cv2.imshow("Detector de Olhos Fechados", image_frame)

        # Se for teclado Enter (tecla 13) deverá sair do loop e encerrar a captura de imagem
        if cv2.waitKey(1) == 13:
            break
    else:
        break

cam_capture.release()
cv2.destroyAllWindows()
```

In [28]:
```
exibir_imagem('imagens/5.olhos/EvidenciaOlhos.png')
```

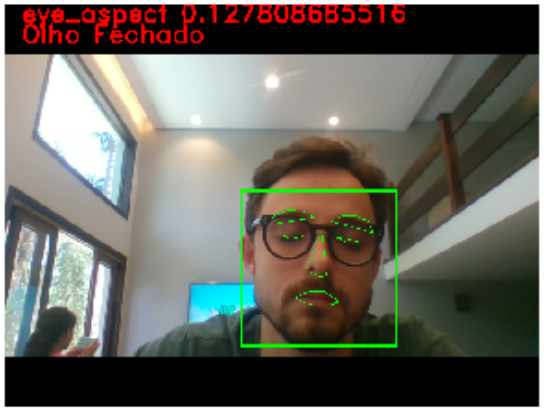

6. Descritor de objetos na cena

A organização do local na casa do entrevistado é um item relevante, pois a partir destes detalhes é possível traçar alguns tipos de perfis que são essenciais para certas posições nas empresas.

Desta forma precisamos construir um algoritmo que realize uma inspeção de objetos na área da câmera que é utilizada para fazer a entrevista. Ao final mostre quais e quantos objetos foram detectados.

É necessário baixar os pesos (modelo de deep-learning) neste link https://pjreddie.com/media/files/yolov3.weights (https://pjreddie.com/media/files/yolov3.weights) e copiar para pasta weights.

In [29]:
```
# Configurações na rede neural YOLOv3
cfg_file = 'cfg/yolov3.cfg'
m = Darknet(cfg_file)

# Pesos pré-treinados
weight_file = 'C:/Users/Igor Chaves/OneDrive/Pessoal/FIAP/Processamento de Imagens/yolov3.weights'
m.load_weights(weight_file)

# Rótulos de classes
namesfile = 'data/coco.names'
class_names = load_class_names(namesfile)
```

```
Loading weights. Please Wait...100.00% Complete
```

Ajuste os valores de NMS (*Non-Maximum Supression*) para regular a sensibilidade de imagens com baixa luminosidade e IOU (*Intersect of Union*) que definie o indicador se o retângulo de identificação de imagem foi adequadamente desenhado.

In [30]:
```
# IMPLEMENTAR
# Definia apropriadamente os valores de limiar de NMS e IOU

nms_thresh = 0.4
iou_thresh = 0.5
```

Separe um imagem que será analisada pelo classificador, após teclar o *Enter*. Armazene no diretório `imagens/local-entrevista.png` .

In [31]:
```
cam_capture = cv2.VideoCapture(0)

while True:
    ret, image_frame = cam_capture.read()

    if ret:
        cv2.imshow("Inspecao Local", image_frame)
        if cv2.waitKey(1) == 13:
            cv2.imwrite('imagens/6.Local/LocalEntrevista.png', image_frame)
            image_capture = image_frame
            break

cam_capture.release()
cv2.destroyAllWindows()
```

A imagem a ser analisada.

In [32]:
```
exibir_imagem('imagens/6.Local/LocalEntrevista.png')
```

Os passos abaixo são para configuração da imagem no padrão que o classificador foi treinado.

In [33]:
```
# Definindo tamnaho do gráfico
plt.rcParams['figure.figsize'] = [24.0, 14.0]

# Carregar imagem para classificação
img = cv2.imread('imagens/6.Local/LocalEntrevista.png')

# Conversão para o espaço RGB
original_image = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)

# Redimensionamento para adatapção da primeira camada da rede neural
resized_image = cv2.resize(original_image, (m.width, m.height))

# Deteteção de objetos na imagem
boxes = detect_objects(m, resized_image, iou_thresh, nms_thresh)

# Desenho no gráfico com os regângulos e rótulos
plot_boxes(original_image, boxes, class_names, plot_labels = True)
```

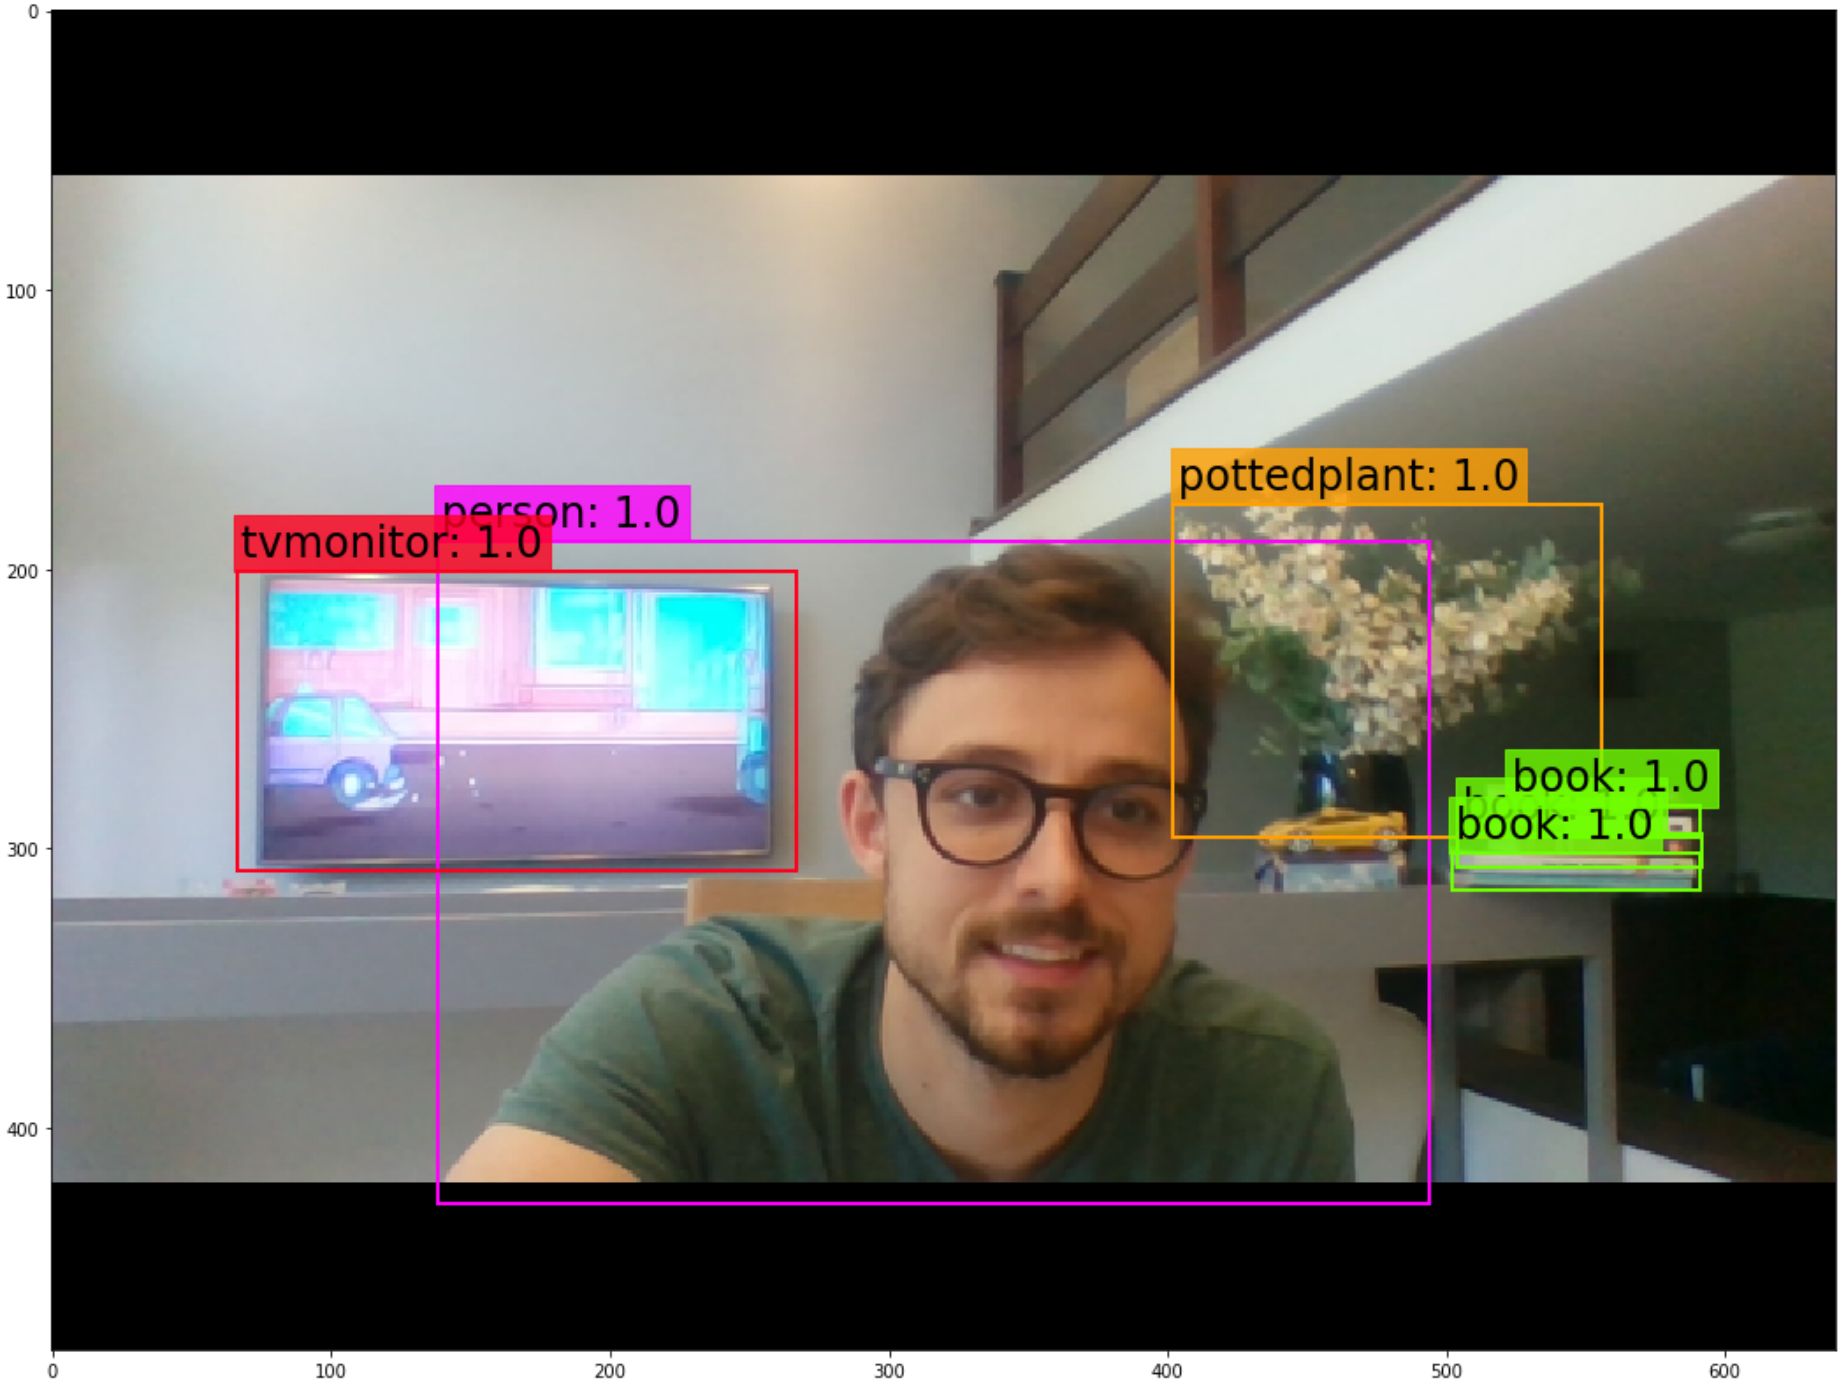
person: 1.0
tvmonitor: 1.0
pottedplant: 1.0
book: 1.0
book: 1.0
0
100
200
300
400
0
100
200
300
400
500
600

Obtenha os objetos identificados a partir da função `list_objects(boxes, class_names)` . Será retornardo uma lista de objetos que deverá ser analisado para contar a quantidade de cada objeto. Se houver mais de um item igual, por exemplo *tvmonitor* ele aparecerá duplicado na imagem.

In [34]:
```
# IMPLEMENTAR
# Conte os objetos identificados pelo classificador, de forma que seja exibido
# objeto 1, quantidade 1
# objeto 2, quantidade 1
# ...

objetos = list_objects(boxes, class_names)

objetosAux = set(objetos)
for objeto in objetosAux:
    print('Objeto ' + str(objeto) + ', Quantidade ' + str(objetos.count(objeto)))
```

```
Objeto person, Quantidade 1
Objeto tvmonitor, Quantidade 1
Objeto book, Quantidade 3
Objeto pottedplant, Quantidade 1
```

Conclusões finais

Pergunta: Diante de todos os desafios propostos (1 ao 6) e soluções encontradas, quais seriam os próximos passos de forma a tornar mais precisos cada atividade, levando em consideração: (1) restrições de processamento em tempo real, (2) sem restrições de processamento em tempo real?

Resposta:

Primeiramente precisamos ampliar a base de treinamento, utilizando varias pessoas, gravando todos os movimentos (olhos, bocejo, sorriso, etc..) e buscando detalhes que podem impactar a analise de reconhecimento como formato do rosto, barba, bigode, etc.... para o modelo, deveremos combinar algorimos de classificação e rede neura para melhorar a qualidade/acerto. Criar analise de sentimento baseada na voz do candidatos.

(1) restrições de processamento em tempo real: ampliar base de treinamento com o modelo melhor treinado, teremos melhor acertividade. será necessario buscar solução para a velocidade, pois, atualmente é lenta. criar base local compactada para em algum momento retroalimentar o modelo

(2) sem restrições de processamento em tempo real: criar solução na nuvem, com armazenamento de todos os dados, para melhorar a qualidade da solução.

In [ ]:
```

```